

Modelli probabilistici per le decisioni:
SmartHouse

Matteo Angelo Costantini, matricola: 795125
Alessandro Longhi, matricola: 794235

Contents

1 Introduzione

I miglioramenti ottenuti in ambito medico hanno portato ad un sensibile aumento dell'aspettativa di vita di ogni individuo, causando un generale invecchiamento della popolazione; il quale rappresenta un importante argomento di studi nell'ambito della sanità. Infatti, aumentando il numero di individui anziani, aumenta anche la necessità di studiare e trovare una soluzione ad alcuni problemi associati alla vecchiaia.

Focalizzarsi sui problemi dovuti all'anzianità significa, quindi, trovare dei modi efficienti per fornire supporto e cure agli individui più anziani direttamente a casa loro; tutto ciò è reso possibile grazie all'uso di sistemi di monitoraggio all'interno delle case, in quanto permettono sia l'aumento della sicurezza dell'abitante, sia il senso di protezione di quest'ultimo, favorendone l'autonomia.

Monitorare le azioni quotidiane degli individui è uno dei task più importanti all'interno di quest'ambito, in quanto permette di descrivere il benessere degli abitanti delle case, sia fisico che mentale. Il monitoraggio delle attività avviene grazie all'uso di alcuni sensori, i quali vengono posti in diversi luoghi all'interno di ogni abitazione.

Questo progetto si colloca nell'ambito appena descritto, in quanto consiste, avendo a disposizione dei dataset contenenti le rilevazioni delle attività e dei sensori in due abitazioni differenti, nella definizione di un modello HMM in grado di inferire le attività data una sequenza di osservazioni derivanti dai sensori. Una volta creata la struttura HMM, è stata effettuata un'analisi riguardante la capacità predittiva del modello.

(INSERIRE LA STRUTTURA DELLA RELAZIONE CHE SEGUIRA).

2 Analisi del dataset

I dataset a nostra disposizione erano quattro, due per ogni abitazione, rappresentanti rispettivamente le attività ed i sensori rilevati all'interno dell'abitazione.

Le abitazioni considerate sono due, etichettate con "OrdonezA" ed "OrdonezB".

2.1 Analisi del dataset A

Per l'abitazione "OrdonezA" sono stati forniti due dataset, uno contenente le attività rilevate, ovvero "OrdonezA_ADLS", ed uno contenente i sensori rilevati, ovvero "OrdonezA_Sensors". Nel primo dataset, quello delle attività, sono descritti i seguenti campi:

- Start_time: data ed ora di inizio della rilevazione di un'attività
- End_time: data ed ora di fine della rilevazione di un'attività
- Activity: attività rilevata nel periodo considerato

in particolare, nella colonna "Activity" sono stati rilevati 10 valori diversi, cioè: Leaving, Toileting, Showering, Sleeping, Breakfast, Lunch, Dinner, Snack, Spare_Time/TV e Grooming.

Il secondo dataset di "OrdonezA" è dedicato alla raccolta dei sensori rilevati. In quest'ultimo sono presenti i seguenti campi:

- Start_time: data ed ora di inizio della rilevazione di un sensore
- End_time: data ed ora di fine della rilevazione di un sensore
- Location: collocazione precisa in cui è posizionato il sensore rilevato
- Type: tipologia del sensore rilevato
- Place: camera dell'abitazione nella quale è posizionato il sensore rilevato

in particolare, nella colonna "location" sono stati rilevati 12 sensori in 4 camere diverse, che, divisi in base al tipo, sono:

- tipo PIR: Shower, Basin, Cooktop
- tipo Magnetic: Maindoor, Fridge, Cabinet, Cupboard
- tipo Flush: Toilet
- tipo Pressure: Seat, Bed
- tipo Electric: Microwave, Toaster

Per entrambi i dataset di A, sono state considerate le rilevazioni ottenute per un periodo di 14 giorni, dal 28-11-2011 al 11-12-2011.

2.2 Analisi del dataset B

Per l'abitazione "OrdonezB" sono stati forniti due dataset, uno contenente le attività rilevate, ovvero "OrdonezB_ADLS", ed uno contenente i sensori rilevati, ovvero "OrdonezB_Sensors".

Nel primo dataset, quello delle attività, sono descritti i seguenti campi:

- Start_time: data ed ora di inizio della rilevazione di un'attività
- End_time: data ed ora di fine della rilevazione di un'attività
- Activity: attività rilevata nel periodo considerato

in particolare, nella colonna "Activity" sono stati rilevati 10 valori diversi, cioè: Leaving, Toileting, Showering, Sleeping, Breakfast, Lunch, Dinner, Snack, Spare_Time/TV e Grooming.

Il secondo dataset di "OrdonezB" è dedicato alla raccolta dei sensori rilevati. In quest'ultimo sono presenti i seguenti campi:

- Start_time: data ed ora di inizio della rilevazione di un sensore
- End_time: data ed ora di fine della rilevazione di un sensore
- Location: collocazione precisa in cui è posizionato il sensore rilevato
- Type: tipologia del sensore rilevato
- Place: camera dell'abitazione nella quale è posizionato il sensore rilevato

in particolare, nella colonna "location" sono stati rilevati 12 sensori in 5 camere diverse, che, divisi in base al tipo, sono:

- tipo PIR: Shower, Basin, Door Kitchen, Door Bathroom, Door Bedroom
- tipo Magnetic: Maindoor, Fridge, Cupboard
- tipo Flush: Toilet
- tipo Pressure: Seat, Bed
- tipo Electric: Microwave

Per entrambi i dataset di B, sono state considerate le rilevazioni ottenute per un periodo di 21 giorni, dal 11-11-2012 al 2-12-2012.

2.3 Discretizzazione dei dati

La lettura dei dati da parte dei sensori e la conseguente rilevazione delle attività vengono effettuate iterativamente, di conseguenza i dati descritti nei dataset iniziali presentano una distribuzione continua; di conseguenza, per ottenere una corretta formattazione temporale dei dati, è necessario effettuare un processo di discretizzazione del tempo.

Il tempo viene quindi diviso in time slices, intervalli regolari spazati da una predeterminata granularità di tempo Δt .

Le rilevazioni di un sensore per ogni time slice t sono denotati come x_t^i indicante se il sensore i si è attivato almeno una volta tra il tempo t ed il tempo $t + \Delta t$, con x_t^i in $\{0, 1\}$.

In una casa con N sensori, verrà quindi definito un vettore di osservazioni $\vec{x}_t = (x_t^1, x_t^2, \dots, x_t^{N-1}, x_t^N)^T$ per ogni time slice.

Ogni istanza del dataset sarà rappresentato da un'etichetta, che corrisponderà all'attività rilevata in quel segmento di tempo.

L'attività nella time slice t , che rappresenta lo stato nel quale è il sistema, è denotato con y_t in $\{1, \dots, Q\}$ per Q possibili stati; di conseguenza ogni istanza del dataset finale sarà rappresentata da un'etichetta y_t indicante l'attività e da un vettore di osservazioni x_t , risultante da una mappatura basata sulla sovrapposizione dell'unità di tempo nella quale è stato rilevato un'attività e si sono attivati i sensori.

Sono stati infine introdotti l'attività "No activity" ed il vettore dei sensori interamente a 0, per rappresentare il fatto che in una time slice non vengano rilevate delle attività o dei sensori.

2.4 Preprocessing dei dati

In seguito all'elaborazione dei dati sono stati ottenuti due dataset, uno per "OrdonezA" ed uno per "OrdonezB".

2.4.1 Conversione dei dataset iniziale

Prima di descrivere la struttura dei dataset ottenuti, è necessario precisare che prima è stata effettuata una conversione del formato dei dataset iniziali; infatti questi sono stati forniti in formato testuale, ma durante la fase di preprocessing sono stati convertiti in file .csv in modo da renderne più semplice la modifica.

Inoltre, ai fini di rendere più semplice l'analisi nelle fasi successive, sono state apportate alcune modifiche ai valori contenuti nei dataset, in particolare:

- le date di inizio e di fine rilevazione sono state convertite in timestamps
- i valori contenuti nelle restanti colonne, presenti sottoforma di stringhe, sono stati mappati su valori interi (ad esempio, in "OrdonezA" nella colonna "Activity", l'attività "Breakfast" è rappresentata dal valore 0, e così via)

Durante queste modifiche, è stato effettuato anche un controllo sulla consistenza di ogni riga, in particolare, sono state eliminate le righe che presentavano una data di inizio rilevazione successiva alla data di fine rilevazione.

2.4.2 Creazione dei dataset finali

Una volta effettuate le modifiche descritte precedentemente, è stato svolto, per ogni abitazione, un lavoro di unione del dataset riguardante i sensori e quello riguardante le attività, in modo da ottenere i dataset finali.

Durante questa fase sono stati introdotte le time slices, che, come sarà presentato in seguito, sono state poste a 60 secondi nella maggior parte della sperimentazione; tuttavia questo parametro è facilmente modificabile.

A causa delle time slices, quindi, le righe nel dataset risultante sono aumentate, in quanto vengono considerati tutti gli intervalli di grandezza Δt partendo dalle 00:00 del primo giorno fino alle 23:59 dell'ultimo.

A questo punto ogni riga è stata completata con lo stato attivo in quella time slice, che ne rappresenterà la label y_t , dal vettore dei sensori attivi in quella time slice \vec{x}_t , identificati da "Location", "Type" e "Place" ed infine da un valore che ne indica il momento della giornata.

Si ricorda che è stata aggiunta un'attività denominata "No Activity" per riuscire ad etichettare tutte quelle time slices nelle quali non veniva rilevata nessuna attività; inoltre è stato posto un vettore di soli 0 nel caso in cui in una time slice non vengano trovati dei sensori accesi.

2.5 Dataset finali

Alla fine del preprocessing vengono generati due dataset finali: "OrdonezA" ed "OrdonezB".

Ognuno di questi dataset contiene i seguenti campi:

- Timestamp: data ed ora di inizio della time slice
- Activity: valore intero che rappresenta una determinata attività rilevata nella time slice
- Sensors: vettore di bit avente 1 nelle posizioni sulle quali sono mappati i sensori attivi in quella time slice
- Period: valore intero rappresentante il momento della giornata nel quale è situata la time slice

3 Creazione del modello HMM

3.1 Hidden Markov Models

Lo standard HMM è un modello probabilistico definito in termini di una variabile osservabile x_t e di una variabile nascosta y_t ad ogni istante discreto di tempo t .

Nel caso considerato in questo progetto, la variabile osservabile è formata dalle osservazioni dei sensori al tempo t , mentre la variabile nascosta è l'attività da riconoscere.

L'HMM è definito dalle due seguenti assunzioni:

- la variabile nascosta al tempo t , denominata y_t , dipende solamente dalla variabile nascosta precedente, ovvero y_{t-1}
- la variabile osservabile al tempo t , denominata x_t , dipende solamente dalla variabile nascosta al tempo t , ovvero y_t

Di seguito verranno descritti i fattori che specificano il funzionamento di un modello HMM.

La distribuzione di probabilità a priori $P(y_t)$ esprime la probabilità che lo stato y_t sia lo stato iniziale della sequenza.

La distribuzione di osservazione $P(x_t|y_t)$ è la probabilità che lo stato y_t generi l'osservazione x_t .

La distribuzione di probabilità di transizione $P(y_t|y_{t-1})$ indica la probabilità di passare da uno stato all'altro. Questi valori sono ricavabili dalla *Conditional Probability Table*.

Queste tre distribuzioni descritte precedentemente sono sufficienti alla definizione di un modello.

3.2 Creazione delle matrici

Per creare le matrici è bisogna avere un train set che permetta di trovare le probabilità necessarie alla creazione della matrice. Di seguito verrà spiegato come sono state ottenute le varie matrici.

3.2.1 Creazione della matrice delle probabilità iniziali

Di seguito verrà introdotto il metodo usato per calcolare la matrice delle probabilità iniziali, che sarà una matrice $1 \times n$, dove n è il numero degli stati nascosti (nel nostro caso, le attività).

Per trovare questa matrice, è stato effettuato il conteggio del numero di volte in cui uno stato nascosto si presentava all'interno del train set; una volta ottenuti i valori, questi sono stati divisi per il numero di elementi totali del trainset, ottenendo così le probabilità a priori.

3.2.2 Creazione della matrice delle transizioni

Di seguito verrà introdotto il metodo usato per calcolare la matrice delle transizioni, che sarà una matrice $n \times n$, dove n è il numero degli stati nascosti (nel nostro caso, le attività).

In questa matrice, il generico elemento $M[i][j]$ indica la probabilità di essere giunti nello stato j , partendo dallo stato i . Per calcolare la matrice, viene effettuato, nel train set, il conteggio del numero di volte che si passa dallo stato i allo stato j ; questo valore verrà poi diviso per il numero totale di volte in cui si è passato dallo stato j .

3.2.3 Creazione della matrice delle emissioni

Di seguito verrà introdotto il metodo usato per calcolare la matrice delle emissioni, che sarà una matrice $n \times m$, dove n è il numero degli stati nascosti (nel nostro caso, le attività) ed m il numero delle osservazioni (nel nostro caso, i sensori).

In questa matrice, il generico elemento $M[i][j]$ indica la probabilità di emettere l'osservazione j , partendo dallo stato i . Per calcolare la matrice, viene effettuato il conteggio del numero di volte, all'interno del train set, che dallo stato i viene emessa l'osservazione j ; questo valore verrà poi diviso per il numero totale di volte in cui è stato emesso j .